

硕 士 学 位 论 文

基于雷达数据与相机信息的无人船障碍物感知 与定位

**Obstacle Perception and Location of Unmanned Surface Vessel
Based on Radar Date and Camera Information**

作 者 姓 名: _____ 倪桦
学 科 专 业: _____ 交通运输工程
学 号: _____ 1120191037
指 导 教 师: _____ 关巍
学 位 类 别: _____ 专硕
培 养 单 位: _____ 大连海事大学
答 辩 时 间: _____ 2022 年 6 月 5 日

大连海事大学

Dalian Maritime University

大连海事大学

研究生学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下进行研究工作所取得的成果。尽我所知，除文中已经注明引用内容和致谢的地方外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对论文所涉及的研究工作做出贡献的其他个人和集体，均已在论文中以明确的方式标明或致谢。

若有不实之处，本人愿意承担相关法律责任。

作者签名：_____倪桦_____ 日期：_____2022_____年_____6_____月_____7_____日

摘 要

随着人工智能的不断发展,无人驾驶技术逐渐成为各国重点关注的对象。无人船,作为未来开发海洋矿物资源的重要平台,也成为当下的研究热点,因此其相关技术的深入研究就显得更加重要。其中,环境感知系统是无人船能否进行安全航行的关键。然而现有的传感器目标检测技术良莠不齐,检测的准确性和鲁棒性都有待改进。在此背景下,本文使用激光雷达与摄像头信息相融合的方法,对无人船行进过程中的周围环境进行检测,主要研究内容如下:

(1) 实现了激光雷达与摄像头数据的深度融合。分别对两传感器的数据及工作原进行分析,建立了两传感器在空间和时间上的配准。先将两者的信息进行预处理,接着使用随机采样一致性算法将在点云库(PCL)中处理过的点云进行聚类,提取出水平面点云,并使用 K 均值聚类算法对图像进行聚类并分割,得出可能的障碍物所在区域。接着将剩余的点云数据投影到分割后的图像上,两者融合进一步确定了障碍物所在位置。最后将两传感器分别获得的障碍物距离信息利用长短时记忆神经网络(LSTM)进行拟合,预测出更贴合实际距离的距离值。

(2) 对障碍物进行类别检测。通过对比各个版本的 YOLO 目标检测算法的优缺点,选择出最符合无人船实时目标检测要求的 YOLOv3-tiny 算法,该算法在检测速度上优势明显,且对于硬件的要求低,较可以满足实验的整体要求。

(3) 提出了网格避障决策算法。先对图像进行二值化处理将障碍物从背景中分割出来,再对分割后的图像进行网格划分,判断障碍物是否影响无人船的航行安全,最后通过获取无人船执行避碰操作时所需要的转向角,从而辅助船舶安全航行决策。

本文完成了无人船在航行过程中视觉感知系统的设计及实现,通过两种传感器数据的融合,确定了障碍物所在的区域、位置及障碍物类别等信息,为未来无人船避障研究打下坚实的研究基础。

关键词: 点云库; 随机采样一致性; K 均值聚类; 长短期记忆神经网络; YOLOv3-tiny 算法

Abstract

With the continuous development of artificial intelligence, self-driving technology has been the focus of the all countries. Unmanned surface vessel, as an important platform for the exploration and utilization of marine mineral resources in the future, has also become a current research focus, so the in-depth study of its related technologies is more important. Among them, the environment perception system is the key to the safe navigation of unmanned surface vessel. However, the existing sensor target detection technology is good and bad, the accuracy and robustness of detection need to be improved. In this context, this thesis uses the method of lidar and camera information fusion to detect the surrounding environment of the unmanned surface vessel in the process of moving. The main research contents are as follows:

(1) Realize the deep fusion of lidar and camera data. The working principle and data information of the two sensors are analyzed, and the registration of the two sensors in space and time is established. Firstly, the information of the two sensors is preprocessed. Then, the point cloud processed in the point cloud library (PCL) is clustered using the random sampling consistency algorithm, the horizontal plane point cloud is extracted, and the K-means clustering is used to segment the image to obtain the area where the obstacle is located. After that, the remaining point cloud data is projected onto the segmented image, and the location of the obstacle is further determined. Finally, the obstacle distance information obtained by the two sensors is fitted with a long-short-term memory neural network (LSTM) to predict a distance value that is more suitable for the actual distance.

(2) Class detection for obstacles. By comparing the advantages and disadvantages of each version of the YOLO target detection algorithm, the YOLOv3-tiny algorithm that best meets the real-time target detection requirements of unmanned surface vessel is selected. This algorithm has obvious advantages in detection speed and low hardware requirements, which meets the overall requirements of the experiment.

(3) Proposed a grid obstacle avoidance decision algorithm. Firstly, use the binarization algorithm to process the image to segment the obstacles from the background. Then, divide the image into grids to determine whether obstacles affect the navigation safety of the unmanned surface vessel. Finally, the safe navigation of the unmanned surface vessel is guaranteed according to the obtained steering angle.

The full text comprehensively completes the design and implementation of the visual perception system of the unmanned surface vessel during navigation. Through the fusion of the two sensor data, the information such as the area, location and category of the obstacle is determined, which lays the foundation for the obstacle avoidance of the unmanned surface vessel.

Key Words: Point cloud library; Random sampling consistency; K-means clustering; Long and short term memory neural network; YOLOv3-tiny algorithm

目 录

摘 要	I
Abstract	II
1 绪论	1
1.1 论文的研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于摄像头的目标检测方法	3
1.2.2 基于激光雷达的目标检测方法	4
1.2.3 基于多传感器融合的目标检测方法	4
1.3 论文的主要内容及章节安排	5
2 传感器标定及数据预处理	8
2.1 双目摄像头	8
2.1.1 摄像头坐标系转换	9
2.1.2 双目摄像头标定	12
2.2 三维激光雷达	14
2.2.1 激光雷达坐标转换	15
2.2.2 激光雷达数据采集及解析	16
2.3 激光雷达与摄像头联合标定	17
2.3.1 空间同步	17
2.3.2 时间同步	18
2.3.3 联合标定结果	19
2.4 本章小结	20
3 图像与点云融合的障碍物检测	21
3.1 灰度图像的障碍物识别	21
3.1.1 图像预处理	21
3.1.2 基于 K-means 聚类的图像分割	22
3.2 三维点云的障碍物识别	23
3.2.1 点云预处理	24
3.2.2 水平面提取	24
3.3 两传感器信息融合	25
3.3.1 距离融合	25
3.3.2 点云向图片投影	30

3.3.3	距离预测	30
3.4	本章小结	32
4	基于卷积神经网络的障碍物检测	33
4.1	卷积神经网络	33
4.1.1	YOLOv1 检测算法	33
4.1.2	YOLOv2 检测算法	35
4.1.3	YOLOv3 检测算法	39
4.2	无人船目标检测深度神经网络模型	41
4.2.1	模型选择	42
4.2.2	YOLO3-tiny 网络模型	42
4.3	模型训练及结果分析	42
4.3.1	检测模型的训练	42
4.3.2	目标检测结果与对比分析	43
4.4	本章小结	45
5	无人船避障决策算法设计及避障试验验证	46
5.1	无人船试验平台设计	46
5.1.1	硬件系统架构	46
5.1.2	软件系统架构	48
5.2	避障决策算法设计	49
5.2.1	网格法	49
5.2.2	“网格法”的具体实现	51
5.3	本章小结	52
6	结论与展望	53
6.1	本文的主要研究成果	53
6.2	工作展望	54
	参 考 文 献	55
	致 谢	59
	作者简历及攻读硕士学位期间的科研成果	- 60 -
7	大连海事大学学位论文授权使用声明	62

图表目录

图目录

图 1.1	无人船系统组成	2
图 1.2	技术路线图	7
图 2.1	双目摄像头	8
图 2.2	世界坐标系到相机坐标系	9
图 2.3	相机坐标系到图像坐标系	10
图 2.4	两坐标平面图	10
图 2.5	坐标平移	11
图 2.6	角点检测	13
图 2.7	图像校准	13
图 2.8	校正后图像	14
图 2.9	激光雷达	14
图 2.10	激光雷达扫描及坐标示意图	16
图 2.11	激光雷达点云图	17
图 2.12	坐标变换流程图	17
图 2.13	激光雷达与摄像头联合标定	18
图 2.14	激光点云与图像数据时间配准方法	19
图 2.15	联合标定图	19
图 2.16	点云-图像映射结果图	20
图 3.1	预处理效果图	22
图 3.2	分割前后图	23
图 3.4	分割对比图	25
图 3.5	传感器安装示意图	26
图 3.6	障碍物测量原理图 1	26
图 3.7	障碍物测量原理图 2	27
图 3.8	LSTM 网络结构	28
图 3.9	算法流程图	29
图 3.10	点云投影图	30
图 3.11	两种算法误差比较	31
图 4.1	YOLO 算法原理	33
图 4.2	YOLO 网络结构	34

图 4.3	预测框	38
图 4.4	Darknet-53 结构图	39
图 4.5	YOLOv3 网络结构图	40
图 4.6	YOLOv3-tiny 网络结构图	41
图 4.7	分类标签	43
图 4.8	分类结果图	44
图 5.1	无人船系统组成	46
图 5.2	岸基控制中心	47
图 5.3	船载控制系统	47
图 5.4	船载控制软件体系架构	48
图 5.5	岸基监控软件体系架构	48
图 5.7	网格算法原理图	50
图 5.8	二值化图像	51
图 5.9	划分结果	51

表目录

表 1.1	常用传感器特性	2
表 2.1	激光雷达主要技术参数	15
表 3.1	两种算法结果比较	31
表 3.2	测距实验结果	32
表 4.1	YOLOv2 改进策略	36
表 4.2	Darknet-19 的基本结构	37
表 4.3	网络训练参数	43
表 4.4	测试结果对比	44
表 5.1	网格信息	52

1 绪论

1.1 论文的研究背景及意义

随着第三次工业革命信息技术产业的大发展以及第四次工业革命智能化产业发展的来临,无人装备制造领域取得了快速发展。近年来,随着船舶智能化程度的提高,无人船作为人工智能的一个重要分支逐渐受到人们的关注。无人船^[1]是无人水面航行器(Unman Surface Vehicle)的简称,是集环境感知、行为决策与规划、反馈控制功能^[2]于一体的综合系统。它是海洋技术发展过程中,为了提高环境感知信息的准确性、实时性及安全性所诞生的产物。因此,必须加强及不断完善对无人船所涉及的相关技术的研究。

本文研究的主要内容为确保无人船在航行过程中实时、准确地感知周围的环境,从而进行避障决策的问题,即感知模块的设计与应用。无人船感知模块是决定无人船能否进行准确避障的基础,其主要功能是探测船身周围的环境,从而使无人船在行驶过程中能够凭借感知系统实时、准确地感知到船身前方的障碍物^[3],如礁石、其他船舶等形态及距离信息,并快速做出决策,驶向安全的航线,避免碰撞的发生。

针对无人船在行驶过程中复杂而又多变的海上环境,不同种类的传感器对环境的感知能力都有一些自身的优势和不足之处,现在最常用的有单/双目摄像头、激光雷达、毫米波雷达及超声波雷达^[4]等,它们的特点如表 1.1 所示。摄像头^[5]提供丰富的颜色信息和物体轮廓,可以用来提取物体的不同特征,但其易受天气及光线等因素影响,无法获取稳定、准确的深度信息;激光雷达^[6]传感器提供了物体的精确三维位置和结构,但垂直分辨率低,易受风雪等天气影响;毫米波雷达^[7]环境适应能力强,但不具备障碍物识别能力;超声波雷达价格低,处理数据简单快捷,但探测范围小,易受干扰。为了增强目标检测精度,本文同时使用双目摄像头和激光雷达两个传感器,它们可以结合各自的优缺点,有较好的互补性。

表 1.1 常用传感器特性
Tab. 1.1 Characteristics of common sensors

类别	优点	缺点
激光雷达	探测距离远，稳定性、精度高，可获取三维信息。	价格贵，易受极端天气影响，垂直分辨率低。
摄像头	价格低，技术已相对成熟，可获取丰富颜色信息。	光线影响较大，稳定性不高。
毫米波雷达	稳定性和环境适应能力强。	易受噪声干扰，无法识别障碍物。
超声波雷达	价格低，数据易处理。	噪声影响严重，探测范围小。

1.2 国内外研究现状

随着无人驾驶领域逐渐取得了快速发展，无人机和无人汽车也逐渐走进人们的生活，此外，无人船也不甘示弱，发展迅速，逐渐渗入到人们的生活中。




图 1.1 无人船系统组成
Fig. 1.1 Unmanned ship system composition

广义的无人船是指可以执行人为指定的某些任务，并根据任务对其相应的功能、性能进行设计的一种水面机器人；狭义的无人船则是指具有一定机动能力的水面自主、半自主、遥控搭载体。无人船由两个主要的系统组成，即平台和任务载荷系统，它们之间通过通用接口进行集成，具体如图 1.2 所示。平台系统包括平台本体分系统、动/能分系统、感知分系统、控制分系统、通信分系统和交互分系统，六个分系统共同组成无人船最基本的通用单元，可以独自操作运行，是为完成不同任务而设计的搭载体平台。其中，感知分系统主要是通过传感器来获取船舶周围的环境信息，并对信息进行处理，检测出目标所在位置，为无人船避障提供基础，现将按以下三方面来阐述目标检测的研究现状。

1.2.1 基于摄像头的目标检测方法

早在几十年之前，摄像头因其低廉的价格及获取颜色和轮廓信息能力强已被广泛应用于目标分类识别的领域中，并取得了很多优秀的研究成果和实用方法。现有的基于摄像头^[8]的无人船目标识别方法主要分为基于传统图像特征的提取方法和基于深度学习和机器学习的特征提取方法^[9]。

一般传统的特征提取方法实现步骤一般为先提取图像的特征，常用方法有方向梯度直方图(HOG)^[10]、尺度不变特征变换(SIFT)^[11]等，再利用支持向量机(Support Vector Machine, SVM)、Adaboost 等分类器来对特征进行分类^[12-14]，传统检测方法即使有一定的效果，但随着人工智能的迅速发展，传统的特征提取方法在性能上逐渐达不到要求，候选区域选择存在大量冗余、时间效率低，目标检测的精度更是远远不够。因此，国内外学者们研究出了深度学习等更好的特征提取方法。它利用大数据对模型进行训练，使其自动学习特征，并准确地进行目标检测，该技术已被广泛运用于无人驾驶领域中。深度学习这一概念最早是由 Geoffrey Hinton 等人于 2006 年所提出的，随着深度置信网络(Deep Belief Network, DBN)^[15, 16]的发表与其在图像识别领域的优异表现，得到了众多高校及公司的青睐，成为了目标识别的主流技术。

在目标检测领域的深度学习网络中，有 two-stage 和 one-stage 两种架构。其中 two-stage 是分两步完成对目标的检测，即先提出备选框，再对备选框进行预测，代表网络有 RCNN^[17]、SPPNet^[18]、Fast RCNN^[19]、Faster RCNN^[20]等。而 one-stage 网络则是使用一步来完成备选框和预测，现有的主流网络有 SSD^[21]和 YOLO^[22]等，有效地提高了目标检测的速度。

1.2.2 基于激光雷达的目标检测方法

三维激光雷达可通过同时发射的多束激光信号接收到大量且密集的点云数据,从而根据点云数据来进行目标识别。由于激光雷达的探测范围广、检测精度高且夜视能力也很强,因此近几年来受到了国内外的广泛应用,尤其是在目标检测的研究中。

传统的点云目标检测方法的步骤主要是点云预处理、获取感兴趣区域(ROI)、特征提取及目标定位等步骤,孔栋等人^[23]先提取出 ROI 的点云,再对该点云数据进行聚类,根据聚类对象内部特征点的向量模长与夹角来进行目标识别,准确度较高;Asma Azim 等人^[24]以密度阈值为聚类依据来完成对点云数据的聚类操作,并利用聚类后的目标点云边界框的长、宽、高的比值来进行目标检测,此方法不适宜运用在有遮挡的背景下。

随着深度学习逐渐被运用到各个领域中都取得了更好的效果,研究人员也开始将深度学习技术应用到三维激光点云的目标检测之中。牛津大学在 2015 年提出使用投票方案(Voting)实现了稀疏网络上的卷积运算,方式虽简单,但成功实现了对点云数据的处理;2017 年苹果公司提出了体素网格(VoxelNet)^[25]这一端对端的深度学习网络,网络首先将点云进行体素化并提取体素中点云的特征,将其送到卷积层中进行卷积,最后使用 RPN(Region Proposal Network)对目标进行回归和检测,方法简单但对稀疏的点云作用不大,容易得到空的体素。后来学者们又提出了 PointNet^[26]以及在其基础上改进的 PointNet++^[27]模型,都是先提取每一个点的特征进行学习,再将这些局部特征进行合并,得到全局特征。检测精度较好,但实时性差、速度很慢,不适合用于无人驾驶领域。

1.2.3 基于多传感器融合的目标检测方法

由于目标检测过程中,每种传感器在不同性能上都会不可避免地存在一些缺陷,若无人船进行目标检测时只使用单一类型的传感器,必定存在难以准确、稳定、实时地对周围环境进行感知的问题。因此,国内外众多研究人员选择纷纷提出了通过使用多传感器信息融合的方式,提高目标检测的准确率。运用最多的组合方案主要为:摄像头与激光雷达^[28],摄像头与毫米波雷达^[29]。对于摄像头与毫米波雷达融合方法,东京工业大学^[30]提出将毫米波雷达获取到的数据进行网格划分从而实现数据分类、分割,再以图像序列为显示结果达到障碍物检测。日本丰田公司采用毫米波雷达与摄像头融合方法建立障碍物分类系统。先使用毫米波雷达得到 ROI 并将其送入神经网络算法中,在 ROI 中识别障碍物,整套神经网络训练效果很好但实时性差^[31]。谭力凡^[32]由毫米波雷达得到感兴趣区域,对 ROI 进行投影,并使用 Adaboosting 算法检测投影区域的 Haar-like 目标矩形

特征,完成目标的检测。那田^[33]利用毫米波雷达获取 ROI 后再使用 Harr-like 特征和 Adaboost 分类器来识别目标,但该算法具有局限性,只能用来识别车辆且对于有遮挡的目标及较小目标识别能力差。目前国内外学者都是采用深度学习的方法对雷达及摄像头所分割出的 ROI 进行目标检测与识别,由于本文主要针对无人船的障碍物检测识别与测量,为满足研究课题需要,使用激光雷达与双目摄像头两传感器信息融合来进行无人船的避障研究。

三维点云数据可以得到障碍物准确的深度信息,而且性能相对稳定,受天气、光线等因素影响较小,而摄像头价格低且可以获得丰富的颜色和纹理信息,拍摄的图像可用来精确识别障碍物。为了充分发挥并结合两传感器的优势,许多学者已经提出了较好的融合方法。如陆怡悦^[34]先利用激光雷达提取出感兴趣区域并使用混合高斯模型滤除图像背景,再使用形态学和矩形包围框标记出障碍物。麦新晨^[35]对点云数据进行聚类处理,将传感器之间的坐标进行转换得到转换矩阵从而将点云数据投影到图像上,对投影的区域进行边缘检测,得到障碍物的轮廓从而实现目标检测识别。Rubaiyat 等人^[36]提出了一种 RGB+XYZ 模型,它是一种 6D 空间融合模型。该模型利用 PIHOG 来提取尺度不变特征并训练 SVM 向量机来检测障碍物。邢皎玉^[37]也是先将激光点云数据进行聚类提取 ROI 并将其向图片投影,得到重合的 ROI 区域,接着运用 Sobel 算子和 OTSU 算法在该 ROI 中提取出障碍物的阴影及几何对称特征,再对这些特征进行进一步分析、融合,实现障碍物的检测。

综上所述,如今的无人驾驶领域目标识别技术已是应有尽有,但大多数都是用在无人车中,至于无人船,其发展前景广阔但对目标识别技术的要求还未得到满足,无论是实时度还是准确度方面都有待改进,本文所研究的内容就是在保障无人船安全航行的基础上快速并准确地对前方障碍物进行识别。

1.3 论文的主要内容及章节安排

无人船的感知系统是一个软件和硬件相结合的复杂系统,是无人船航行过程中的保护伞。因此本文主要解决无人船航行过程中的避障问题,即通过三维激光雷达与摄像头的融合作用,考虑船舶在正常天气及风浪流影响不大的情况下,检测并识别障碍物,得到障碍物与船舶之间的距离并预测出障碍物的类别等信息,最后通过栅格避障算法进行无人船避障。

全文的研究内容及章节安排如下:

第1章：绪论。主要介绍了本论文所涉及到的技术的研究背景，并分别阐述了它们在国内外的的发展及研究现状，最后列出全文的研究内容及各章节的具体安排。

第2章：传感器及数据的预处理。分别对激光雷达与摄像头所获得的信息进行解析，方便后续使用。接着对两传感器的坐标进行转换，实现数据降维。最后对相机及雷达进行联合标定，解决了时间和空间的不同步问题。

第3章：传感器数据融合。对摄像头采集到的图像信息进行平滑、去噪等操作并分割出可能的障碍物所在区域，再对激光雷达采集到的点云数据进行提取，得到剩余点云数据并向图片投影，确定障碍物所在区域。最后将两传感器所获得的障碍物距离信息进行训练拟合，预测出更准确的距离值。

第4章：障碍物分类检测。首先分别介绍现有的目标检测算法，找出更适合于无人船所使用的检测算法。通过与其他算法的性能比较，突出本文所选的目标检测算法的优势。

第5章：“网格”避障决策算法。先介绍了无人船试验平台的软件、硬件的系统结构，接着列出了无人船海上避碰规则约束条件。最后将经过二值化处理的图像进行网格划分，计算各个障碍物占所在栅格的百分比，划分出安全航行区域并判断无人船是否需要避障决策。

第6章：结论与展望。总结全文，提出论文中所存在的不足之处及未来的研究发展过程中可改进的方向。

全文的技术路线如下图所示：




图 1.2 技术路线图

Fig. 1.2 Technology roadmap

2 传感器标定及数据预处理

摄像头与激光雷达对障碍物的联合检测中，当摄像头主要承担对障碍物轮廓的检测任务时，激光雷达作为辅助进行障碍物确认；当激光雷达主要承担空间测量任务时，摄像头作为辅助提供拟合数据提高预测准确性。

摄像头为了实现空间物体中的各个点与图像中的点相对应，需要建立物体从三维世界映射到摄像头二维成像平面上的几何模型。由于摄像头在成像过程中因其自身透镜及外界某些因素等影响会导致拍摄的图像存在一定的畸变，因此要得到更准确的图像数据就需要对摄像头进行校准（Camera Calibration），即通过实验计算求解出摄像头成像几何模型参数，这些参数包括：内参（Intrinsic Parameters）、外参（Extrinsic Parameters）以及畸变系数（Distortion Coefficients）。最常用的摄像头标定方法有 Tsai 算法^[38]和张正友标定算法^[39]，求解的模型参数，都能够达到较高的标定精度。如今 MATLAB 已针对该方法封装了 camera_calibration 标定工具，本文基于此工具标定摄像头。

激光雷达与摄像头都是在各自的坐标系下独立工作，分别生成点云数据和图像信息，若要将二者进行融合，找到二者各自检测目标在空间中的对应关系，必须继续联合标定。目前主流的联合标定方式是借助棋盘格等标定图案找到点云与图像之间的对应关系并建立几何约束，最终得到准确的外参信息。

2.1 双目摄像头

摄像头能够获取外界环境丰富的颜色、纹理等信息，被广泛应用于物体的检测识别中。本文选用小觅深度版双目摄像头，如图 2.1 所示，型号为 D1300-IR-90/Color。



图 2.1 双目摄像头

Fig. 2.1 Binocular camera

该摄像头最大分辨率为 2560×720 ，帧率为 60fps，通过 USB2.0/3.0 接口进行数据传输和供电，缓存速度为 32Mbyte，数据可靠，同时该摄像头支持 MJPG、YUYV 图像输出格式。

2.1.1 摄像头坐标系转换

(1) 世界坐标系转换到相机坐标系

这两个坐标系都是三维的，所以这一部分就是三维空间转到另外一个三维空间。




图 2.2 世界坐标系到相机坐标系

Fig. 2.2 World coordinate to camera coordinate

上图中， C 为相机坐标系的原点， O 为世界坐标系的原点，要将世界坐标系转换到相机坐标系只需要执行平移和旋转操作，其中 R 表示旋转矩阵， t 为平移向量。公式： $\tilde{X}_{cam} = R(\tilde{X} - \tilde{C})$ ，其中 R 为旋转矩阵， \tilde{X} 表示 x 点在世界坐标系中的位置， \tilde{C} 表示 C 在世界坐标系中的位置， \tilde{X}_{cam} 表示 x 点在相机坐标系的位置。

(2) 相机坐标系转换到图像坐标系

由于图像坐标系是二维的，而相机坐标系却是三维的，因此这部分就是将三维向二维转化的过程。




图 2.3 相机坐标系到图像坐标系

Fig. 2.3 Camera coordinate to image coordinate

上图中， C 是相机中心， p 为图像中心，两坐标系的 Z 轴共线。对图 2.3 进行投影即可得到下面图 2.4。其中 f 为相机的焦距，通过公式 $x = f \times X / Z$ ， $y = f \times Y / Z$ 可得到相机坐标系的点到图像坐标系的投影点。

上述转换实现将相机和图像坐标系转换到同一平面中，转换后坐标如图 2.4 所示，但要达到完全重合 还需要平移操作如图 2.5， p 在像平面坐标系的位置为 (px, py) ，可以得到最终的变换公式：

$$\begin{cases} x = f \times X / Z + px \\ y = f \times Y / Z + py \end{cases} \quad (2.1)$$




图 2.4 两坐标平面图

Fig. 2.4 Two coordinate plane




图 2.5 坐标平移

Fig. 2.5 Coordinate transformation

为了得到相机内参 K 和投影矩阵 P ，将上公式转换为：

$$\begin{bmatrix} f \times X + Z \times p_x \\ f \times Y + Z \times p_y \\ Z \end{bmatrix} = \begin{bmatrix} f & 0 & px & 0 \\ 0 & f & py & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & px & 0 \\ 0 & f & py & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix} \quad (2.2)$$

公式中 K 为：

$$\begin{bmatrix} 1 & 0 & px \\ 0 & f & py \\ 0 & 0 & 1 \end{bmatrix} \quad (2.3)$$

P 为：

$$\begin{bmatrix} 1 & 0 & px \\ 0 & f & py \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} = K[I|0] \quad (2.4)$$

相机坐标系的单位为 m ，图像坐标系的单位为像素点的多少。假设 mx 为在水平方向的 $1m$ 所包含像素点个数， my 为在竖直方向的 $1m$ 所包含像素点个数，那么 K 转换为：

$$\begin{bmatrix} mx & 0 & 0 \\ 0 & my & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} f & 0 & px \\ 0 & f & py \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} fx & 0 & cx \\ 0 & fy & cy \\ 0 & 0 & 1 \end{bmatrix} \quad (2.5)$$

其中 fx 、 fy 、 cx 和 cy 就是相机内参数矩阵得到的四个参数。

(3) 世界坐标系转换到图像坐标

世界坐标系到相机坐标系公式： $\tilde{X}_{cam} = R(\tilde{X} - \tilde{C})$ ，为了方便公式之间的转换，可用矩阵形式表示为：

$$X_{cam} = \begin{bmatrix} \tilde{X}_{cam} \\ 1 \end{bmatrix} = \begin{bmatrix} R & -R\tilde{C} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \tilde{X} \\ 1 \end{bmatrix} = \begin{bmatrix} R & -R\tilde{C} \\ 0 & 1 \end{bmatrix} X \quad (2.6)$$

已知相机坐标系到图像坐标系的投影矩阵 P 为： $K[I|0]$ ，则世界坐标系转换到图像坐标的公式为：

$$x = K[I|0]X_{cam} = K[R|-R\tilde{C}]X \quad (2.7)$$

最终得到的 P 为： $K[R|t]$ ，其中 t 为 $-R\tilde{C}$ 。

综上所述， K 为相机内参，是一个固有属性； R 和 t 都为相机外参，其中 R 为旋转矩阵， t 为平移向量。

2.1.2 双目摄像头标定

双目摄像头标定的基本步骤：

- (1) 准备一个棋盘格靶标；
- (2) 从多角度拍摄图像(大于 15 张)；
- (3) 提取图像中的角点；
- (4) 求出相机的内参；
- (5) 求出镜头的畸变系数；
- (6) 得到最佳值。

本文以 Matlab 工具箱为标定工具、采用张正友标定法实现摄像头标定，采集不同角度和距离的棋盘格图像并对其进行角点检测、校准，结果分别如图 2.6 和图 2.7 所示。得到相机的内部参数如下所示：

左相机参数：

$$M_{左} = \begin{bmatrix} 403.0527 & 1.0448 & 287.9333 \\ 0 & 400.1519 & 244.1548 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.8)$$

右相机参数：

$$M_{右} = \begin{bmatrix} 403.9294 & 1.2073 & 294.5784 \\ 0 & 402.9122 & 283.6214 \\ 0 & 0 & 1 \end{bmatrix} \quad (2.9)$$




图 2.6 角点检测

Fig. 2.6 Corner detection




图 2.7 图像校准

Fig. 2.7 Image calibration

最终得到左坐标系相对于右坐标系的旋转矩阵 R 和平移向量 T :

$$R = \begin{bmatrix} 0.9996 & -0.0039 & 0.0292 \\ 0.0036 & 0.9999 & 0.0108 \\ -0.0292 & -0.0107 & 0.9995 \end{bmatrix} \quad (2.10)$$

$$T = [-99.6408 \quad 0.3283 \quad 4.7716] \quad (2.11)$$

使用如上参数对双目摄像头进行校正，得到的校正对齐图像如下图所示。




图 2.8 校正后图像

Fig. 2.8 The corrected image

2.2 三维激光雷达

激光雷达（Light Detection and Ranging, LIDAR）^[40]是一种非接触式主动扫描传感器，其工作过程中通过向四周发射激光束并采集遇到目标后反回来的信号来实现实时目标检测和测距。这些信号经过自身处理即形成可精确描述雷达所在三维空间信息的点云数据。

本文选用镭神智能公司产品系列中的lslidar-32C 三维激光雷达其外观如图2.9所示：



图 2.9 激光雷达

Fig. 2.9 LIDAR

该激光雷达具有 200m 的有效测量范围，测距精度达 $\pm 3\text{cm}$ ，通道为 32 路，并且可以在 360° 水平视场和垂直视场 $-16^\circ \sim +15^\circ$ 中每秒产生多达 130 万个点云数据，能够满足距离维度测量的实时性^[22]。其主要技术指标如表 2.1 所示。

表 2.1 激光雷达主要技术参数

Tab. 2.1 Main technical parameters of lidar

型号	C32 型
测距方式	脉冲式
激光波段	905nm
激光等级	1 级(人眼安全)
激光通道	32 路
测量范围	100—200 米
测距精度	$\pm 3\text{cm}$
单回波数据速率(双回波)	64 万点/秒(128 万点/秒)
垂直 视场角	$-18^\circ \sim +14^\circ$
水平 视场角	360°
垂直 角度分辨率	0.33° 、 0.66° 、 1° 、 2° 、 3°
水平 角度分辨率	5Hz: 0.09° 、10Hz: 0.18° 、20Hz: 0.36°
扫描速度	5Hz、10Hz、20Hz
通信接口	以太网、PPS
供电范围	9V—36VDC
操作温度	$-20^\circ\text{C} \sim +60^\circ\text{C}$
储存温度	$-20^\circ\text{C} \sim +85^\circ\text{C}$
冲击	500m/sec^2 , 持续 11ms
震动	5Hz—2000Hz, 3G rms
防护等级	IP67
尺寸	120mm*110mm
重量	1600g

2.2.1 激光雷达坐标转换

激光线倾角为 ω ，根据测量距离 r 来确定点云在扫描平面中的坐标 X_0 。

$$X_0 = \begin{bmatrix} x_0 \\ y_0 \\ 0 \end{bmatrix} = \begin{bmatrix} r \sin \omega \\ r \cos \omega \\ 0 \end{bmatrix} \quad (2.8)$$

在激光雷达开始执行扫描操作时，扫描面和雷达坐标系所处平面的夹角为 α 。将扫描面所处坐标系向激光雷达坐标系转换，则得到的旋转矩阵 R_x 为：

$$R_x = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \sin \alpha \\ -\cos \alpha \\ \cos \alpha \\ \sin \alpha \end{bmatrix} \quad (2.9)$$

最终得到空间中某个测量点在激光雷达坐标系中的坐标为：

$$X_c = \begin{bmatrix} x \\ y \\ z \end{bmatrix} = R_x \times X_0 \quad (2.10)$$




图 2.10 激光雷达扫描及坐标示意图

Fig. 2.10 Lidar scan and coordinate diagram

2.2.2 激光雷达数据采集及解析

实验是在 ROS (Robot Operating System) 系统^[41]下对激光雷达数据进行采集，首先在系统中安装雷达对应的数据采集程序包，雷达通过 UDP 协议端口向外界发送数据包。其中，数据包的组成包括 42 字节以太网包头和 1206 字节的有效载荷，长度为 1248 字

节。有效载荷由 8 字节的包头 Header、1196 字节的数据 Data 和 2 字节的包尾 Tail 组成。雷达的测量数据共 1200 字节，它由 12 个数据块 (blocks) 组成，每个数据块长度为 100 字节。一个数据块包括 2 字节 0xffee 固定值的标志位；2 字节 Azimuth 的相对水平角度信息；32 个通道的 channel 点云数据 (每个通道 3 字节)。每组 32 通道 channel 数据 (UDP 包封装顺序) 对应雷达的一组 32 次激光不同发射时刻的测量数据。ROS 系统中原有的 Rviz 工具可以显示出实时三维点云数据，下图为某一时刻的雷达点云数据图。




图 2.11 激光雷达点云图

Fig. 2.11 Lidar point cloud image

2.3 激光雷达与摄像头联合标定

2.3.1 空间同步

在无人船中摄像头与激光雷达的安装位置是固定不变的，因此两者之间的坐标系必然存在一个固定的转换关系。将两者进行联合标定即可找到同一时刻同一位置中激光点云数据和图像中对应的像素点。坐标变换具体步骤如下图所示。




图 2.12 坐标变换流程图

Fig. 2.12 Coordinate transformation flow chart

由上图可知联合标定^[42, 43]的目的是将激光雷达坐标系转换到摄像头坐标系下，从而得到雷达相对于摄像头的 3×4 刚体变换矩阵，其包括旋转矩阵 R 和平移向量 T 。原理图

如下图所示。其中， $O_C-X_C Y_C Z_C$ 为相机坐标系； $O_L-X_L Y_L Z_L$ 为雷达坐标系； $O_W-X_W Y_W Z_W$ 为世界坐标系。




图 2.13 激光雷达与摄像头联合标定

Fig. 2.13 Joint calibration of lidar and camera

因此，激光雷达坐标系到图像像素坐标系转换关系可表示为：

$$Z_C \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{dx} & 0 & u_0 \\ 0 & \frac{1}{dy} & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} R & T \\ \vec{0} & 1 \end{bmatrix} \begin{bmatrix} X_W \\ Y_W \\ Z_W \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & u_0 & 0 \\ 0 & f_y & v_0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} R & T \\ \vec{0} & 1 \end{bmatrix} \begin{bmatrix} X_W \\ Y_W \\ Z_W \\ 1 \end{bmatrix} \quad (2.11)$$

式中， f_x 和 f_y 为图像坐标系中某像素点分别在 x 、 y 方向上的距离； Z_c 为图像深度距离与实际距离的比例因子； (u, v) 为图像坐标系的坐标； (u_0, v_0) 为相机光轴和成像平面的交点坐标； R 和 T 分别为相机与雷达之间的旋转矩阵和平移向量； (X_w, Y_w, Z_w) 为雷达点云的坐标。

2.3.2 时间同步

多传感器的数据融合不仅需要在空间上保持一致，还需要时间上的同步^[44]。由于各个传感器拥有不同的采样频率，总是存在一些差异，必然会导致不同传感器采样数据时间上不同步，信息不一致^[45]。因此本文使用软件同步的方法使各个传感器的每帧数据同步到统一的某一时间上即时间戳，即将扫描周期短的传感器数据统一到扫描周期相对较长的传感器数据上^[46]。本文所用激光雷达的采样帧速率约为 40 帧/秒，相机采样帧速率为 60 帧/秒，如下图所示：




图 2.14 激光点云与图像数据时间配准方法

Fig. 2.14 Time registration method of laser point cloud and image data

图中绿色虚线框表示激光雷达采集频率，蓝色虚线框表示相机采集频率，横轴表示统一的时间戳。将传感器在每一时刻的采样数据都记录在同一个时间序列上，由于激光雷达的频率比摄像头要低，因此以激光雷达的采样数据作为配准标准，当雷达采样完成后，寻找与其最近邻的图像数据，这样便完成了两传感器数据的时间匹配，如图中红色方框所示。

2.3.3 联合标定结果

本文采用 ROS 中自带的联合标定数据包实现激光雷达点云与摄像头图像数据的同步采集，并使用无人驾驶软件 Autoware^[47]中的 Calibration Tool Kit 工具箱实现激光雷达与摄像头的联合标定，操作简单，可不断进行实验，因此准确性高。




图 2.15 联合标定图

Fig. 2.15 Joint calibration chart

在进行联合标定时，将标定板分别放在正前方、正上、正下、左边、左上、左下、右边、右上、右下九个位置进行数据采集。数据采集完毕后，利用 ROS 中安装的 Autoware 中的 Calibration Tool Kit 工具箱进行数据处理，具体标定过程如上图 2.15 所示。

标记 9 组以上数据后，使用 Calibrate 进行参数计算并利用 Project 验证标定结果。若红色散点全部集中在标定板上，则标定结果合格；反之重新标记并计算。




图 2.16 点云-图像映射结果图

Fig. 2.16 Point cloud - image mapping result diagram

通过 Autoware 得到的三维激光雷达与摄像头之间的旋转矩阵 R 与平移向量 T 如下式所示。

$$R = \begin{bmatrix} -9.99 \times 10^{-01} & -1.21 \times 10^{-02} & -5.29 \times 10^{-03} & 1.99 \times 10^{-02} \\ 8.22 \times 10^{-03} & -2.57 \times 10^{-01} & -9.66 \times 10^{-01} & -1.07 \times 10^{-01} \\ 1.03 \times 10^{-02} & -9.66 \times 10^{-01} & 2.57 \times 10^{-01} & -1.41 \times 10^{-01} \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2.12)$$

$$T = \begin{bmatrix} 4.72 \times 10^{-03} & -7.33 \times 10^{+00} & 3.75 \times 10^{-03} & 2.24 \times 10^{-03} & 4.51 \times 10^{+01} \end{bmatrix} \quad (2.13)$$

2.4 本章小结

本章分别对激光雷达与摄像头的工作原理、传感器特性、数据形式等进行详细分析，并在空间、时间上均进行数据同步处理，从而得到两传感器对应准确的数据信息，最后根据这些数据信息分别完成对二者自身的标定和联合标定，得到两传感器的联合标定参数，为后续障碍物识别及检测工作做准备。

3 图像与点云融合的障碍物检测

3.1 灰度图像的障碍物识别

灰度图像不仅可以清晰地呈现出物体的外部纹理信息，还可轻易辨别遮挡物，更直观地反映出物体的轮廓信息。本文通过双目相机原理，将拍摄图片转化为灰度图进行处理。首先将灰度图进行高斯滤波^[48]、中值滤波^[49]等操作实现图像的平滑去噪，再利用 K-means 算法对障碍物进行轮廓提取及聚类分割，生成光学障碍物图。

3.1.1 图像预处理

在图像处理的过程中会涉及到许多步骤，例如采集、输入等，还有设备因为天气等外部原因，这些都会产生各种噪声极大的影响到后续的图像分割的精度^[50]。

本文使用中值滤波和高斯滤波来消除图片上的噪声及孤立点。

(1) 中值滤波

中值滤波是使用一个滑动窗口来滤除噪声，即用某种结构的二维滑动模板，将此模板内的所有像素按照其值的大小排成单调上升（或下降）的二维数据序列并取排在中间的像素值赋给当前待处理的像素值。

此二维序列中值滤波输出为：

$$g(x, y) = \text{medf} \{ f(x-k, y-1) \} \quad (3.1)$$

其中， $f(x, y)$ 和 $g(x, y)$ 分别表示为原图像和处理后的图像； $k \in \omega$ ， ω 为输入的二维模板。

(2) 高斯滤波

高斯滤波器在处理图像上，最主要是通过高斯核的一个二维的卷积算子实现对图像进行模糊化从而去除图像中的噪声点。其中一维和二维高斯分布分别表示为：

$$G(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} \quad (3.2)$$

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (3.3)$$

滤波的具体步骤为：

- ①移动高斯核的中心元素，并将它覆盖在待处理图像中指定像素的正上方；

②将输入图像的像素值作为权重，乘以该高斯核；

③将上面各步得到的结果相加作为输出。

经过中值滤波和高斯滤波处理后的图像如图 3.1 所示。




图 3.1 预处理效果图

Fig. 3.1 Pre-processed image

由于环境、设备等因素导致采集到的原图中存在大量的高斯和椒盐噪声，因此先通过中值滤波去除图像中的椒盐噪声，之后再对图像进行高斯滤波去除高斯噪声，得到干净的灰度图。

3.1.2 基于 K-means 聚类的图像分割

K-means 算法^[51]是以空间中 K 个点为中心进行聚类，将最靠近它们的对象归为一类。通过不断地进行迭代操作，更新各个聚类中心点，直至得到最好的聚类结果。

假设 K-means 聚类算法中：

样本集： $D = \{X_1, X_2, \dots, X_m\}$

聚类中心集合： $U = \{U_1, U_2, \dots, U_K\}$

簇的集合： $C = \{C_1, C_2, \dots, C_K\}$

要将样本点划分为 K 个类簇，则每个样本点离簇的聚类中心越近，即为最优：

$$\min E = \sum_{i=1}^K \sum_{X \in C_i} \|X - U_i\|_2^2 \quad (3.4)$$

$$U_i = \frac{1}{C_i} \sum_{X \in C_i} X \quad (3.5)$$

其中， E 越小，则簇内的相似度越高。具体算法流程如下所示：

①将数据集聚类成 K 个类簇；

- ②从数据集中随机抽取 K 个点作为质心;
- ③分别计算所有点到各个质心之间的距离,并将这些点划分到与它距离最近的质心所在的簇;
- ④所有质心都有点聚集之后,重新选取新的质心。
- ⑤比较新老两个质心,如果两者之间的距离值小于设定的阈值,则表示新的质心位置变化不大,收敛稳定,此时聚类结果已达最佳,算法终止。
- ⑥如果新老质心之间的距离值大于阈值,返回继续重复执行第三步到第五步,直到算法终止。

分割前后图像如图 3.2 所示。



图 3.2 分割前后图

Fig. 3.2 Before and after segmentation images

如上图可以看出,该算法将水面上可能存在的障碍物粗略的分割出来,分割效果良好,海面上的礁石以及跨海大桥都已从背景中分离了出来,但海浪凸起的部分还未去掉,因此还需要与点云进行融合,进一步确定障碍物所在的准确区域。

由于灰度图所呈现的物体轮廓信息清晰且对遮挡的部分区分明显,因此本部分以灰度图为基础,对其进行滤波去噪处理,得到干净的灰度图方便对其进行障碍物分割操作。利用如上算法即可将水面上可能的障碍物轮廓从背景中分割出来,为之后的融合做准备。

3.2 三维点云的障碍物识别

激光雷达扫描的信息传输至计算机端后,即可显示出三维点云数据。要检测出海面上存在的障碍物就需要先对预处理后的点云进行聚类,去除水平面部分的点云,以此得到可能的障碍物区域。

3.2.1 点云预处理

由于原始点云的密度不规则，且因遮挡、设备传输等问题会使原始点云中存在大量离群点、误识别点等噪声点，因此就需要对无用的点云进行滤波处理以提高计算效率和水面提取的精确度。本文使用基于半径的滤波方法对噪声点进行剔除。其算法核心思想为先设置点云半径内周围最小点云数，若给定的目标点周围的点云数小于设置数字则认为该点为噪声点要对其进行删除处理，最终处理结果如下图所示。



图 3.3 点云预处理前后图

Fig. 3.3 Before and after point cloud pretreatment

3.2.2 水平面提取

RANSAC 算法^[52]是针对如平面、圆柱等特定模型的最优估计算法。算法假设观测数据集是一组包含模型局外点和局内点的集合，它通过重复迭代达到获取包含最多局内点的模型参数并找到这个具体模型。通过 PCL 点云处理库完成该算法，其具体执行步骤如下：

①在初始点云中随机抽取三个点 (a,b,c) ，这三点所确定的平面方程为：

$$n \cdot x + d = 0 \quad (3.6)$$

其中， n 为平面法向量， d 为平面截距，分别表示为：

$$n = (b - a) \times (c - a) \quad (3.7)$$

$$d = -n \cdot a \quad (3.8)$$

②计算每个样本点 x_i 到步骤 1 中所得平面的距离：

$$D_i = (n \cdot x_i + d)^2 \quad (3.9)$$

③若 $D_i \leq D_{threshold}$ ，则将该点划为局内点，反之则认为是局外点。记录此轮局内点的总个数 N_j 以及模型参数 n 、 d ；其中， $D_{threshold}$ 为选取的固定阈值。

$$N_j = Num(x_i), D_i \leq D_{threshold} \quad (3.10)$$

式中 $Num(x_i)$ 代表样本点总数。

④当迭代次数达到设定值或者 $N_j = Num(x_i)$ ，算法结束。

⑤重复 1、2、3 步，直到满足步骤 4 的结束条件，取 N_j 最大值所对应的平面参数 n_b ， d_b 作为最佳拟合水平面。

最终拟合平面方程为：

$$0.11507x + 0.0649108y + 0.991234z + 0.559586 = 0 \quad (3.11)$$

实际分割效果如图 3.4 所示：




图 3.3 分割对比图

Fig. 3.4 Segmented contrast map

3.3 两传感器信息融合

上面部分已对点云数据与图像数据进行处理，分别得到二者检测到的障碍物可能存在的区域并将其从背景中分离出来，为点云向图像投影做准备。

3.3.1 距离融合

(1) 传感器的安装

本文选择将两传感器对称地安装在船头中心点的两侧。为了使两传感器尽量在同一直线上对障碍物进行距离的测量，且互相不干扰，所以将摄像头中线点与雷达底层中心点安装在在一条直线上，安装位置如下图所示：




图 3.4 传感器安装示意图

Fig. 3.5 Sensor installation diagram

图中，A 为双目摄像头，B 为激光雷达，两者的中心点在同一条直线上。取与两传感器中心点在同一条直线上的船头中心点 O 为实际测距点。

(2) 障碍物测量

此处考虑到障碍物在两个传感器之间和之外两种情况。

①当障碍物在两传感器之间时， R_1 、 R_2 分别为摄像头和激光雷达测得的距离，G 为观测点，位置在 A 和 B 的中点，O 为目标中心垂直于 A、B 连接线的点。此处 AB 为两传感器的距离，安装时已知。设 AO 距离为 x ，则 OB 为 $AB - x$ ，由式(10)即可以求出 x 的值。具体如下图所示：




图 3.5 障碍物测量原理图 1

Fig. 3.6 Schematic diagram of obstacle measurement 1

$$R_1^2 - x^2 = R_2^2 - (AB - x)^2 \quad (3.12)$$

即 x 为:

$$x = \frac{R_1^2 - R_2^2 + AB^2}{2AB} \quad (3.13)$$

此时:

$$\begin{cases} OG = x - \frac{AB}{2} \\ OC = \sqrt{R_2^2 - (AB - x)^2} \end{cases} \quad (3.14)$$

$$CG = \sqrt{OG^2 + OC^2} = \sqrt{R_2^2 - (AB - x)^2 + \left(x - \frac{AB}{2}\right)^2} \quad (3.15)$$

②当障碍物在两传感器之外时, 具体如图所示:




图 3.6 障碍物测量原理图 2

Fig. 3.7 Schematic diagram of obstacle measurement 2

如上图可知, 此时的 x 为:

$$x = \frac{R_2^2 - R_1^2 - AB^2}{2AB} \quad (3.16)$$

则 CG 为:

$$CG = \sqrt{OC^2 + OG^2} = \sqrt{R_1^2 - x^2 + \left(x + \frac{AB}{2}\right)^2} \quad (3.17)$$

由上述两种情况得出的 CG 值即为两传感器在观测点 G 测得的融合后的障碍物距离值。但由于两传感器都易受到外界环境的干扰, 因此对于真实物体的测量数据与真实距离数据总是存在一定的偏差, 因此需要对融合后的距离数据进行进一步的优化。

(3) 距离融合

LSTM 神经网络是特殊的循环神经网络^[53, 54]，它充分的考虑了样本的时序相关性，对其非线性关系解释较好。因此本文采用该模型来对传感器测得数据与真实距离进行拟合并预测。

LSTM 的网络结构如下图所示。




图 3.7 LSTM 网络结构

Fig. 3.8 network structure

图中，本时段的输入为上一时间段的单元状态 C_{t-1} 、输出 h_{t-1} 和本时段的输入 x_t 。结构中含有遗忘门 f 、输出门 o 、输入门 i 三个门，输出结果是本时段的 h_t 和 C_t ；而本时段 y_t 和本时段单元状态 C_t 作为下一阶段的状态，具体计算公式如下：

门控单元：

$$f_t = \sigma\left(\left[W_f^t, V_f^t\right] \cdot \left[X_t, h_{t-1}\right]^T + b_f^t\right) \quad (3.18)$$

$$i_t = \sigma\left(\left[W_i^t, V_i^t\right] \cdot \left[X_t, h_{t-1}\right]^T + b_i^t\right) \quad (3.19)$$

$$o_t = \sigma\left(\left[W_o^t, V_o^t\right] \cdot \left[X_t, h_{t-1}\right]^T + b_o^t\right) \quad (3.20)$$

存储单元：

$$\tilde{c}_t = \tanh\left(\left[W_c^t, V_c^t\right] \cdot \left[X_t, h_{t-1}\right]^T + b_c^t\right) \quad (3.21)$$

$$c_t = i_t \cdot \tilde{c}_t + f_t \cdot c_{t-1} \quad (3.22)$$

输出状态:

$$h_t = o_t \cdot \tanh(c_t) \quad (3.23)$$

其中, W 、 V 为输入量的权值, b 为偏置向量, 它们用来调控激活函数的输入。




图 3.8 算法流程图

Fig. 3.9 Algorithm flow chart

算法具体执行步骤如上图 3.9 所示，其中样本数据是由第二章所提出的时间戳中选取两传感器对应的最近邻时刻的距离值，由该过程进行模型建立及距离值优化、预测，即可得到更贴近于真实值的距离数据。

3.3.2 点云向图片投影

为测试本文所提出的点云以及图像分割方法，在学校附近的海上做了具体实验，所选水域深度平均 6m，风向是东北风，风速为 1.9-2.4m/s，气温为 31℃，最大浪高 0.4m，所有环境因素均满足实验要求。此处海上有石头和跨海大桥两种障碍物。点云与图像的融合结果如图 3.10 所示。




图 3.9 点云投影图

Fig. 3.10 Point cloud projection images

由图 3.10 可以看出，二者重叠部分，编号为 1、2 的两组礁石即为障碍物所在区域，融合后的效果更加准确。由于雷达安装角度问题，并没有扫描到远处的桥，而摄像头相比于激光雷达对前方的视角更开阔一些，因此二者也可以起到相互补充的作用。

3.3.3 距离预测

为了验证本文提出的拟合及预测算法的准确度，实验时还使用了经典最小二乘法（OLS）作为对比。OLS 是一种通过最小化误差的平方和寻找数据的最佳函数匹配的算法。它可以通过曲线拟合优化求得未知的数据。

两种算法对同一目标在不同距离时的预测值与真实值的对比如表 3.1 所示。其中真实值与综合测量值是在室内获得的，通过激光测量仪来测得船头中心点与预设障碍物之

间的真实距离,同时以每二十厘米为间隔,记录两传感器感知到的障碍物距离数据并计算得到综合测量值作为模型训练参数。

由表 3.1 的数据可以看出,LSTM 比 OLS 预测的值更加贴近于真实值,准确度更高,且随着迭代次数的增加,两种算法的误差率差会更加明显,如图 3.11 所示。

表 3.1 两种算法结果比较

Tab 3.1 The result of the two algorithms are compared

编号	真实值/cm	综合测量值/cm	OLS 预测值/cm	LSTM 预测值/cm
1	20	21.37	21.06	20.02
2	40	41.72	40.07	30.97
3	60	50.85	60.74	60.11
4	80	70.49	80.93	79.06
5	100	100.75	100.27	100.14
6	120	121.43	121.38	121.23
7	140	138.03	138.59	138.92
8	160	157.94	158.44	160.31
9	180	179.37	179.13	180.74
1	200	195.49	200.65	200.35

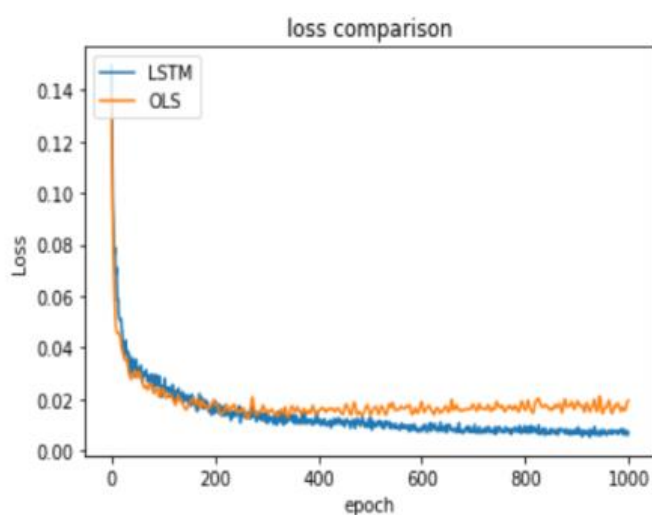


图 3.10 两种算法误差比较

Fig. 3.11 Comparison of error between two algorithms

因此,随着距离数据的增大以及迭代次数的增加,LSTM 预测模型在对数据拟合及预测的准确性方面更具优势。

以 4.1 中图 3.10 所感知的两块礁石 1、2 为例，测量并预测他们与船头之间的距离，具体数据如表 3.2 所示。

表 3.2 测距实验结果
Tab 3.2 Ranging experiment results

编号	真实距离值 /cm	雷达测量 值/cm	相机测量 值/cm	综合测量 值/cm	LSTM 预测值 /cm
1	128.31	126.72	113.47	131.18	128.02
2	141.07	142.86	137.25	139.62	140.14

表中真实距离值为激光测距仪分别测得 1、2 两组礁石的距离，由于其测量精度很高，因此可以作为实际距离来验证 LSTM 算法预测值的准确性。

如上实验，使用两传感器不仅感知出了礁石的位置并能较准确地预测出礁石与船头之间的距离，更好的保障航行安全。

3.4 本章小结

本章首先分别对图像与点云数据分别进行聚类，得到障碍物可能存在的区域，接着对该区域进行分割，将其从背景分离出来。再将分割后的点云数据向图片中进行投影，此时认为点云与图像重合的部分即为障碍物所在区域，从而为无人船避障决策提供数据基础。

同时，本章创新的提出了一种距离融合方法，首先选取雷达与摄像头中心点为测量点，并利用该点根据两种传感器的测量值计算出该点与障碍物的测量距离，再与实际距离进行拟合训练，这样在以后无法知道实际值的情况下系统可以得到准确的预测距离值，保障航行安全。

4 基于卷积神经网络的障碍物检测

随着卷积神经网络的发展, 现已出现了各式各样的网络结构, 如残差网络(Residual Network, ResNet)^[55]和 VGG 网络(Visual Geometry Group)^[56]等, 由于它们自身存在的优缺点, 使它们分别适合不同要求的目标检测工作。本章将根据本文研究的需求筛选出适合的神经网络。

4.1 卷积神经网络

利用卷积神经网络实现目标检测的目的就是为了解决图像里的物体具体是什么类别和在什么位置的问题。输入一幅图像, 输出的结果是图像中每个物体的类别和位置信息并用包围框将物体圈出来。现在已有的目标检测架构有两种, 即 two-stage 和 one-stage。二者区别在于 one-stage 网络生成的 anchor 框只是一个逻辑结构, 仅对数据块执行分类和回归操作, 而 two-stage 网络生成的 anchor 框会映射到 feature map 的区域, 再将该区域重新输入到全连接层进行分类和回归, 即所有 anchor 映射的区域都要进行分类和回归, YOLO^[57]是 You Only Look Once 的缩写, 意为只看图片一次就可以直接输出结果。YOLO 现今总共发布了五个版本, 其中 YOLOv1 是整个 YOLO 系列的基础, 之后的系列都是在 YOLOv1 的基础上作出逐步改进, 不断提升算法的性能。

4.1.1 YOLOv1 检测算法

(1) 算法原理





图 4.1 YOLO 算法原理
Fig. 4.1 Principle of YOLO algorithm

$$\Pr(\text{Object}) \times \text{IOU}_{pred}^{truth} \quad (4.1)$$

每个 bounding box 要预测目标位置与长宽即 (x, y, w, h) 和 confidence 五个值, 每个网格还负责预测类别信息 C 。因此最后的输出为:

(2) 网络结构



由上图可知网络中借鉴了 GoogLeNet 模型^[58]结构, 包含了 24 个从图像中提取特征的卷积层和 2 个预测输出的类别概率值和位置信息的全连接层(用 1×1 和 3×3 的卷积层代替了 inception 模块)。

在测试的时候, 每个网格所预测的目标类别(class)信息乘以 bounding box 预测的 confidence 信息, 即可得到预测的 box 属于哪一类别及其可信度。

$$\Pr(Class_i | Object) \times \Pr(Object) \times IOU_{pred}^{truth} = \Pr(Class_i) \times IOU_{pred}^{truth} \quad (4.3)$$

算式等号左边三项分别为预测的类别信息及 confidence 值, 最终得到的 box 信息可通过设置固定阈值分别来确定或剔除掉得分高和得分低的 boxes, 从而得到最终准确的检测结果。

(3) 损失函数

每个网格都包含了预测目标所需的坐标、confidence 值、类别这三个信息, 而损失函数的作用就是将这三者的误差进行平衡。YOLOv1 的损失函数如下所示。

$$\begin{aligned} & \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{ij}^{obj} (x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \\ & + \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{ij}^{obj} (\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2 \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{ij}^{obj} (C_i - \hat{C}_i)^2 \\ & + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{ij}^{noobj} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} 1_{ij}^{obj} \sum_{c \in classes} (p_i(c) - \hat{p}_i(c))^2 \end{aligned} \quad (4.4)$$

式中 S^2 表示划分的所有网格数, x 、 y 、 w 、 h 代表实际坐标值, C 代表 confidence 值, p 代表目标类别的概率, 而 \hat{x} 、 \hat{y} 、 \hat{w} 、 \hat{h} 、 \hat{C} 、 \hat{p} 则代表对应的预测值。 1_{ij}^{obj} 用来判断第 i 个网格中的第 j 个 box 是否负责这个 object 并由 IOU 最大的 bounding box 负责该 object, 1_{ij}^{noobj} 用来判断第 i 个网格中的第 j 个 box 是否存在 object, λ_{coord} 表示有目标时的损失权重, λ_{noobj} 表示无目标时的损失权重。

4.1.2 YOLOv2 检测算法

在 YOLOv1 网络模型的基础上, Joseph Redmon 等人对其进行了改进, 提出了改进版网络模型并将其命名为 YOLOv2^[59]。如表 4.1 所示, YOLOv2 为了提升模型的召回率和定位的准确度, 提出了多种改进策略, 并有效地提高了 mAP。

表 4.1 YOLOv2 改进策略

Tab. 4.1 YOLOv2 improvement policy

	YOLO								YOLOv2
Batch norm?	✓	✓	✓	✓	✓	✓	✓	✓	✓
hi-res classifier?		✓	✓	✓	✓	✓	✓	✓	✓
convolutional?			✓	✓	✓	✓	✓	✓	✓
anchor boxes?			✓	✓					
new network?				✓	✓	✓	✓	✓	✓
dimension priors?					✓	✓	✓	✓	✓
location prediction?					✓	✓	✓	✓	✓
passthrough?						✓	✓	✓	✓
multi-scale?							✓	✓	✓
hi-res detector?									✓
VOC2007 mAP	63.4	65.8	69.5	69.2	69.6	74.4	75.4	76.8	78.6

具体改进如下：

(1) 批处理(Batch Normalization)

YOLOv2 网络中舍弃了 Dropout,卷积后全部加入 Batch Normalization(BN), 经过 Batch Normalization 处理后的网络可以提升 2%的 mAP,并且对网络的每一层的输入都做了归一化处理, 使得模型收敛等容易。

(2) 高分辨率的分类器

YOLOv2 增加了在数据集上使用 448×448 来调整分类网络这一中间过程, 使模型提早适用于高分辨率的输入。在使用了高分辨率分类器后, 其 mAP 提升了约 4%。

(3) Anchors 及维度聚类

为了解决当遇到图片中物体繁多且形状多样导致的定位不准, 召回率降低的问题, YOLOv2 参考 Faster-RCNN 模型中 Anchors 机制, 采用 k-means 算法通过聚类来得到合适的先验框来预测 bounding box, 增强模型兼容性。且将 k-means 中的聚类标准由欧氏距离改为以 IOU 作为分类标准, 具体公式如下所示:

$$d(box, centroid) = 1 - IOU(box, centroid) \quad (4.5)$$

这样就有效地剔除掉了由于目标尺寸差异导致的误差。

(4) Darknet-19 网络模型

相较于 YOLOv1, 该网络中将原本的 24 个卷积层和 2 个全连接层改为 19 个卷积层和 5 个最大池化层, 整体的 GooleNet 减少从而降低计算量。最后用平均池化层代替全连接层进行预测, Darknet-19 的基本结构如下。

表 4.2 Darknet-19 的基本结构

Tab. 4.2 Darknet-19

Type	Filters	Size/Stride	Output
Convolutional	32	3×3	224×224
Maxpool		2×2/2	112×112
Convolutional	64	3×3	112×112
Maxpool		2×2/2	56×56
Convolutional	128	3×3	56×56
Convolutional	64	1×1	56×56
Convolutional	128	3×3	56×56
Maxpool		2×2/2	28×28
Convolutional	256	3×3	28×28
Convolutional	128	1×1	28×28
Convolutional	256	3×3	28×28
Maxpool		2×2/2	14×14
Convolutional	512	3×3	14×14
Convolutional	256	1×1	14×14
Convolutional	512	3×3	14×14
Convolutional	256	1×1	14×14
Convolutional	512	3×3	14×14
Maxpool		2×2/2	7×7
Convolutional	1024	3×3	7×7
Convolutional	512	1×1	7×7
Convolutional	1024	3×3	7×7
Convolutional	512	1×1	7×7
Convolutional	1024	3×3	7×7
Convolutional	1000	1×1	7×7
Avgpool		Global	1000
Softmax			

(5) 细粒度特征

原网络已达到可在 13×13 的特征图上进行预测，可以较准确地检测出大尺度的物体，但对于小尺度，还会有漏检的情况，因此 YOLOv2 使用细粒度特征即添加一个转移层(passthrough layer)，将高、低分辨率特征图的特征叠加到不同的通道。这样 YOLO 检测器便可以使用扩张之后、有更多细粒度特征的特征图，模型的性能得到提高。

(6) 直接位置预测

YOLOv1 对 t_x 和 t_y 的取值范围没有加以限制，这就导致在任意的 cell 中，可以在图片中的各个位置进行预测，使得模型收敛需要很长时间。因此 YOLOv2 在此处进行改进，直接预测 box 相对于 cell 的偏移，即用 logistic 激活函数实现把 ground truth 限制到 0, 1 的区间内。

网络在每个 cell 中预测出五个不同比例的 boxes，它们分别再预测 5 个坐标，即 x 、 y 、 w 、 h 和置信度 C 。假设其中一个 cell 左上角的坐标是 (cx, cy) ，box 的先验宽、高度是 p_w 、 p_h ，则最终预测结果为：

$$\begin{aligned} b_x &= \sigma(x) + c_x \\ b_y &= \sigma(y) + c_y \\ b_w &= p_w e^w \\ b_h &= p_h e^h \\ P_r(object) * IOU(b, object) &= \sigma(C) \end{aligned} \quad (4.6)$$

如下图所示：




图 4.3 预测框

Fig. 4.3 Predict box

式中 b_x 、 b_y 、 b_w 、 b_h 分别表示 bounding box 的真实坐标及长宽； $\sigma(*)$ 为 sigmoid 函数，用来实现坐标的归一化操作； p_w 和 p_h 分别表示经过 k-means 聚类后得到的先验框的长和宽； $P_r(object)$ 表示当前 cell 中存在待检测目标的概率。

模型经过 sigmoid 函数处理后，取值限制在 0-1 之间，使 anchor 只负责其周围的 box，有效的提升了模型效率和网络的收敛速度。

4.1.3 YOLOv3 检测算法

YOLOv3^[60]算法在 YOLOv1 和 YOLOv2 的基础上又进一步做出了如下改进：

(1) Darknet-53：网络由许多规模为 1×1 和 3×3 的卷积层组成（每个卷积层后都会跟一个 BN 层和一个 LeakyReLU）层，算上最后的全连接层一共是 53 个卷积层因此该网络被称为 Darknet-53。其结构图如下所示：




图 4.4 Darknet-53 结构图

Fig. 4.4 Darknet-53 structure

(2) 多尺度特征预测：利用三个特征层进行边框的预测，预测的三个特征层大小分别是 52, 26, 13。它们之间的连接如下图所示，这样的改进更有助于提升对小目标预测的准确度。




图 4.5 YOLOv3 网络结构图

Fig. 4.5 network structure

4.2.1 模型选择

随着深度学习技术的不断发展，它逐渐成为了图像分割、目标检测等领域的主流技术，而采用深度卷积神经网络来进行车辆、船只、行人等障碍物识别也已经被广泛应用于无人驾驶中。现今已有的基于卷积神经网络的目标检测技术主要分类两大类，第一类是 two-stage 算法，该算法主要是通过区域建议网络生成候选框，再根据候选框进行进一步的目标识别和预测，由于其做了两步操作，因此在目标检测的准确度上更胜一筹，但在检测速度上却不尽如人意。第二大类是 one-stage 算法，这是一种端到端的算法，输入图片后可直接对图片中的目标进行类别和位置预测，检测精度高且检测速度快。

本文要实现无人船对障碍物的实时检测，这就要求算法在确保检测精度较高的基础上，检测速度更要尽可能的快速。因此本文使用改进的 YOLOv3-tiny 算法实现海上目标的检测。

4.2.2 YOLO3-tiny 网络模型

YOLOv3-tiny 的网络结构如图 4.6 所示，其结构中共有 23 层网络，其中有卷积层 convolutional(13 个)，池化层 maxpool(6 个)，路由层 route(2 个)，上采样层 upsample(1 个)，输出层 yolo(2 个)等五种不同的网络层。Yolov3-tiny 中，除了 yolo 层之前的那个卷积层(linear)，每个卷积层之后对应的都有 BN 层和激活函数 LEAKY。该算法在 YOLOv3 的基础上将网络进行了压缩，只使用了两个不同尺度的 yolo 输出层，舍弃了 res 层(残差层)，其结构轻巧，因此速度更快且可以在很多硬件上实现。

4.3 模型训练及结果分析

4.3.1 检测模型的训练

本文以 pytorch 深度学习框架实现无人船的目标检测算法，先用 COCO 数据集^[61]来进行模型建立时的训练检测，但由于本文要做的是船舶和礁石的检测，而 COCO 数据集中没有礁石的分类，所以使用自己建立的数据集来进行最终的检测实验。自己建立的数据集里面都是从网上搜集来的各种类型、各个角度、大小的船舶和礁石图片，并在 labelme 中对目标进行打标签操作，总共建立了礁石(rock)和船舶(boat)两种分类打标签的过程如图 4.7 所示。




图 4.7 分类标签

Fig.4.7 Category labels

在此数据集的基础上，对 YOLOv3-tiny 模型进行训练及验证。网络模型的参数配置如下表所示：

表 4.3 网络训练参数

Tab. 4.3 Network training parameter

参数类型	参数值
Batch	64
momentum	0.9
decay	0.0005
steps	10000
Learning_rate	0.001

整体网络在训练过程中的损失值随着迭代次数的改变而逐渐减小，最初的 9000 次下降速度极快，幅度明显，9000 次以后则趋于平缓，最终稳定在 0.1 左右，模型整体处于收敛状态。

4.3.2 目标检测结果与对比分析

YOLOv3-tiny 网络模型训练结束后，得到的网络模型参数被用来测试无人船航行过程中的所拍到的部分图片进行障碍物检测，检测效果如图 4.8 所示。




图 4.8 检测结果图

Fig.4.8 Test result diagram

训练后的网络模型可以有效地检测出各个角度获取到的图片中的船舶和礁石，并将其用矩形框标明，从图中可知，算法整体对图中的目标定位精度较高。

本文最为注重的就是对目标检测的精度以及检测的速度。只有检测速度足够快才能满足无人船实时避障的要求，只有检测精度高，才能保障无人船航行过程中的安全性。因此本文最终选择 FPS(frames per second)和 AP(average precision)作为无人船目标检测的评价指标。

将 YOLOv3 与 YOLOv3-tiny 两种网络模型分别在数据集上进行的测试，得到的测试结果对比如表 4.4 所示。

表 4.4 测试结果对比

Tab. 4.4 Comparison of test results

算法	Map(%)	平均每帧用时/ms
YOLOv3	59.7	23.7
YOLOv3-tiny	64.8	15.2

由上表可看出, YOLOv3-tiny 的 mAP 值和 FPS 都有所提高, 其中 mAP 值提高了将近 5 个百分点, 平均每帧用时提高了 8.5, 模型在准确度和速度上都可以达到无人船行驶过程中的障碍物检测要求。

4.4 本章小结

本章首先介绍了如何根据现有的神经网络模型选择更适合于无人船目标识别的 YOLO 算法, 接着分别介绍了 YOLOv1、YOLOv2、YOLOv3 的发展及改进, 最终确定选用执行速度更快的 YOLOv3-tiny 作为本文目标检测算法, 自己建立只包含船舶和礁石两种障碍物的数据集并在此数据集上进行训练及验证, 最终实现对船舶及礁石两种可能障碍物的识别。

5 无人船避障决策算法设计及避障试验验证

本课题是依托无人船实验验证平台展开的,由于无人船的系统构成复杂,可根据不同场景的任务所需来安装不同的应用模块。本章对无人船的避障进行实船试验,对目标检测的准确性及避障决策算法的实时性和有效性进行验证。

5.1 无人船试验平台设计

5.1.1 硬件系统架构

无人船的试验平台主要分为岸基控制中心和船载控制系统两部分,平台的硬件系统组成如图所示:




图 5.1 无人船系统组成

Fig. 5.1 The architecture of USV system

岸基控制中心的主体部分由监控系统、数据处理和决策控制等组成,其结构图如图 5.2 所示。整个控制中心的作用为实时接收并进行处理传输电台传回的信息,时刻监控无人船的运行状态,判断前方是否存在障碍物并向无人船发送命令及时做出决策。




图 5.2 岸基控制中心

Fig. 5.2 The shore-based control center

船载控制系统的基本结构如图 5.3 所示。




图 5.3 船载控制系统

Fig. 5.3 The control system of USV

陀螺仪和卫星定位系统负责获取当前状态下无人船的船首向和位置、姿态等信息，通过控制器计算得到合适的航向执行命令，从而控制无人船的航行，安全抵达目的地。遥控接收机主要用来负责接受遥控器发来的指令，控制无人船的模式切换。数据 / 视频

传输电台则是将船舶航行的视频和航行过程中所监测到的数据传回岸基控制中心并接收控制命令，实现无人船的自主避障。

5.1.2 软件系统架构

无人船的软件系统也是分为岸基监控和船载控制两部分。

船载控制的软件架构如图 5.4 所示。




图 5.4 船载控制软件体系架构

Fig. 5.4 The shipboard control software architecture

岸基监控的软件架构如图 5.5 所示。




图 5.5 岸基监控软件体系架构

Fig. 5.5 The shore based monitoring software architecture

其作用是将数据/视频传输电台传过来的所有数据都保存后台数据库中,并实时显示更新无人船的航行状态信息。数据收发全程由 4G 网络提供网络支持,可实现随时随地对无人船的航行状态信息进行监控、遥控,没有空间、距离等条件的限制,这样既可保证无人船航行全程不断联也可以方便开发人员的后续操作。

5.2 避障决策算法设计

无人船在自主航行过程中要想顺利完成任务就必须具备在不明海域仍能安全航行的能力。无论遇到像礁石、河岸这样的静止障碍物还是像其它船舶这样的动态障碍物,都可以迅速感知并最大程度规避碰撞的风险。本文由此创新地提出“网格法”将复杂的问题进行简化降维,同时考虑到无人船为应对其复杂的航行环境,将《国际海上避碰规则》作为无人船与其它船舶会遇时的决策标准^[62, 63],保障无人船在紧迫局面下能既安全又有效地做出避碰决策,为后续的无人船避障操作提供决策建议。

5.2.1 网格法

将前文图像分割出的障碍物目标绘制矩形包围框,根据测出的距离信息,由远及近依次对其进行标号。设定无人船的安全航行距离为 30 米,提取所有在此距离范围内的障碍物矩形包围框,并进行二值化处理,得到各个障碍物的二值化图像,其中二值化处理的阈值通过最大类间方差法(OSTU)^[64]计算得到,其具体实现步骤为:假设存在阈值 T 将图像中的全部像素分为两类 C_1 (小于 T) 和 C_2 (大于 T), C_1 和 C_2 的均值分别为 m_1 、 m_2 , 且图像全局均值为 mG , 则某像素被分为 C_1 或 C_2 类的概率分别为 p_1 、 p_2 。因此就有:

$$p_1 \times m_1 + p_2 \times m_2 = mG \quad (5.3)$$

$$p_1 + p_2 = 1 \quad (5.4)$$

由上述方差的概念可以得到类间方差的表达式为:

$$\sigma^2 = p_1 (m_1 - mG)^2 + p_2 (m_2 - mG)^2 \quad (5.5)$$

把上式化简,将式(1)代入式(3),可得:

$$\sigma^2 = p_1 p_2 (m_1 - m_2)^2 \quad (5.6)$$

其中:

$$p_1 = \sum_{i=0}^k p_i \quad (5.7)$$

$$m_1 = 1/p_1 \times \sum_{i=0}^k i p_i \quad (5.8)$$

$$m_2 = 1 / p_2 \times \sum_{i=k+1}^{L-1} ip_i \quad (5.9)$$

由此遍历 0~255 个灰度级，得到使得式 (5.3) 最大化的灰度级 k 就是最终的阈值。

对每一幅二值图进行网格划分的结果如图 5.7 所示。将船头中点的视角进行降维处理，模拟传感器视角进行扇形网格划分。由于船舶的高度对于降维处理影响不大，只是角度有些变化因此忽略不计。再对每个网格内的各个白像素点进行检测，并求出白像素点占所在网格所有像素点的比例，根据比例的大小判断该网格是否安全，适合通行。若该网格或几个网格在航行船只的正前方，则不适宜继续航行，需要进行避障操作。




图 5.6 网格算法原理图

Fig. 5.7 The schematic of grid algorithm

如图 5.7 所示，O 表示船舶所在位置，而威胁航行安全的障碍物被限制在一个矩形区域 ABCD 内。从图中可以看出，A_7 和 A_8 为危险区域，其他区域为安全航行区域。在二维图像计算中，可以得到 ABCD 顶点在矩形区域的坐标。然后从点 B、D 处画出水平边界线，求相邻直方图网格 A_6、A_9 中心线与水平边界线的交点 E、F。最后，我们计算出最佳的角度 $\angle GOF$ 和 $\angle GOE$ 。

船舶避障一般可以划分为两种类型，即远距离避障和近距离避障。国际海事组织制定的现行海洋法《国际海上避碰规则公约》(COLREGs)有助于远距离避障。为了符合该规则，应遵循“右舷转向为主”的原则。因此， $\angle GOF$ 是无人船避免危险目标所需要的最优航向信号，将无人船的避障问题转化为改道保持问题。

5.2.2 “网格法”的具体实现

第三章已经在摄像头与激光雷达数据融合的过程中确定了实验时障碍物所在的区域及大致轮廓，即得到了两个礁石目标，如图 3.9 所示。为了验证网格法的有效性，首先对两块礁石所在位置进行切割，再分别对二者进行二值化处理操作，执行结果如图 5.8 所示，将背景部分用黑色像素点表示，而前景物体则使用白像素点突出显示，这样就将障碍物完全从背景中分离出来。



图 5.7 二值化图像

Fig. 5.8 The result of thresholding




图 5.8 划分结果

Fig. 5.9 The result of grid division

接着将处理后的图像进行网格划分，共划分了 8 个网格，即 A_1-A_8，划分结果如图 5.9 所示。再对每个网格中白像素点占其所在网格的比例分别进行计算，具体计算结果如表 5.2 所示。

表 5.1 网格信息

Tab. 5.1 The information of grids

网格区域	目标占比(%)
A_1	0.0006
A_2	0.3197
A_3	0.5761
A_4	6.9617
A_5	8.7036
A_6	6.8196
A_7	6.8214
A_8	1.7409
A_9	0.3557
A_10	0.3973
A_11	9.2075
A_12	0.0011

经过如上表格可以看到，A_4、A_5、A_6、A_7 和 A_11 所占像素比较高，存在障碍物的可能性更大，不适宜无人船航行，同时又可以从表 5.2 中看出，其中一个礁石位于船头的正前方，对无人船的航行安全存在威胁，此时无人船需要进行避障决策。可以通过避开白像素点占比较高的网格且考虑船舶海上避碰规则的基础上，进行避障决策，通过计算得到适宜无人船安全航行的转向角为 37.5° ，这样就为下一步进行具体的船舶避障操作提供可靠的避障执行航向命令。

5.3 本章小结

本文主要从软件、硬件两方面介绍无人船仿真试验平台，并介绍了海上船只相遇时的冲突分类及海上避碰规则的约束条件。应用 python 编程实现网格算法，将第三章激光雷达与摄像头信息进行融合得到障碍物所在区域的图像进行二值化处理，并将处理后的图像进行网格划分，计算出障碍物所在区域及安全航行区域，从而得到无人船输出的航向角，为无人船下一步进行有效避障提供基础，保障航行安全。

6 结论与展望

6.1 本文的主要研究成果

无人驾驶已经成为当下全世界最受关注的话题之一，它将成为未来船舶、车辆、飞机等专业领域的研究热点。环境感知作为其最重要的技术之一，最大的难点就在于真实环境复杂多样，传感器的准确性、可靠性难以得到保证，极容易出现误检、漏检等情况。因此，为了解决无人船在航行期间单一传感器无法获得障碍物准确信息的问题，本文提出多传感器信息融合技术来完成对障碍物的探测。既提高了系统的抗干扰性，也降低了系统的不确定性。本文的主要工作如下：

(1) 阐述无人船研究的重要性。综合阐述了国内外有关于无人船发展的历史及背景。接着分析了国内外关于目标检测的先进方法，此处分别介绍了激光雷达、视觉以及激光雷达与视觉信息融合的目标检测方法的发展现状并指出这些方法的优缺点，从而提出本文所使用的目标检测方法，最后对全文各章节的安排进行简述。

(2) 传感器联合标定。首先对激光雷达与摄像头两传感器的特性分别进行分析，对摄像头进行内参校准、畸变矫正、坐标转换，对激光雷达的点云数据进行解析等。接着使用 Autoware 工具完成两传感器的联合标定，该方法通过九点选取来确定标定所需的外参矩阵，可不断进行重复操作，直至得到满意的结果。操作简单、数据读取完整且得到的外参数据较准确，更有助于后续的投影工作。

(3) 传感器信息融合。采用随机采样一致性算法将在点云库(PCL)中处理过的点云进行聚类，提取出水面点云，再将剩余点云数据投影到采用 K 均值聚类分割后的图像上，确定准确的障碍物信息。最后利用长短期记忆(LSTM)神经网络将两传感器融合得到的距离信息与实际距离信息进行学习训练，预测出更贴近于真值的距离数据。提高了无人船环境感知系统的准确性和可靠性，为实时避障提供坚实的基础。

(4) 确定障碍物类别。通过研究现有的目标检测算法，选出更适合无人船的 one-stage 算法，并通过比较，在保证检测精度的同时可以做到检测速度更快，提出了使用 YOLOv3-tiny 的无人船目标检测算法，可以快速高效的检测出障碍物类别并用矩形框进行标注。

(5) “网格”避障决策算法。主要是对障碍物所在区域进行划分，将经过二值化处理的图像进行网格划分，实现降维处理，并对障碍物进行编号，计算各个障碍物所占栅格的百分比，划分出安全航行区域及障碍物所在区域，并判断此时无人船是否需要进

避障决策,当遇到处于无人船正前方的障碍物要计算出无人船避障所需的航向命令角进行船舶避障。最后通过无人船仿真试验验证本文所提算法的可用性。

6.2 工作展望

本文主要研究了无人船的环境感知系统,为保证航行安全而进行障碍物的检测及定位,但无人船是一个涉及人工智能、计算机视觉、信号处理等多门学科的复杂系统。由于本人能力有限且研究时间短,本文仍存在许多问题需要解决。未来,还有以下几个方面值得进一步的改进和深入讨论:

(1) 两传感器的联合标定需要手动进行选取不同的九点,每个点都是一个大圆形区域,很容易超出点云的边界,使最终标定的结果不够准确,投影效果存在偏差。

(2) 距离拟合实验时采用的算法与传统算法比较,的确取得了更好一些的效果,但训练样本较少,随着距离的增加拟合效果逐渐变差。还需扩大数据集,尤其是增加一些较远距离的数据,使训练更充分,预测效果更好。

(3) 本文实验中的传感器识别只考虑到了正常天气及正常海况,未考虑到黑夜造成的视角模糊以及极恶劣天气时风浪造成的船舶剧烈摇晃等情况,因此未来需要多考虑识别的适用场景。

(4) 由于条件限制,本文所有研究所使用的传感器都是普通的设备,激光雷达的探测距离在 200 米以内,且精度有待提高,而摄像头识别距离仅达 20 米左右,获取信息的能力并不满足实际大型船舶对障碍物感知的要求,但全文所提出的各项研究在小型无人船上效果较好,有一定的参考价值。而且在浏览百度百科时曾刷到过一则消息称,我国计划将在 2025 年打造出世界最强、探测范围最大的激光雷达,探测距离可达 1000 公里,虽然这些雷达可能仅用于军事上,但以此技术发展的速度来看,将之后出现的高精度、远距离作业的摄像头和激光雷达应用于大型船舶的目标检测上的目标指日可待。未来可将这些设备应用起来,进一步验证本文提出算法的有效性。

参 考 文 献

- [1] 孙东平. 无人船控制系统设计与实现 [D].青岛: 中国海洋大学, 2015.
- [2] 张显库, 韩旭. 船舶运输安全保障下的智能船舶运动控制策略 [J]. 中国舰船研究, 2019, 14(S1): 1-6.
- [3] CHEN Y S, JILKOV V P, LI X R. Multilane-Road Target Tracking Using Radar and Image Sensors [J]. Ieee Transactions on Aerospace and Electronic Systems, 2015, 51(1): 65-80.
- [4] 杨立成, 李云逸, 张雨龙. 一种超声波雷达自动检测方法及其实现 [J]. 南方农机, 2022, 53(01): 140-142.
- [5] BROGGI A, BERTOZZI M, FASCIOLI A, et al. Visual Perception of Obstacles and Vehicles for Platooning [J]. Ieee Transactions on Intelligent Transportation Systems, 2000, 1(3): 164-176.
- [6] 祖琪, 王丹, 高明华. 基于激光雷达的巡检机器人导航系统研究 [J]. 电子测试, 2018, (22): 32-33.
- [7] 张钰, 林雨田, 高利. 基于毫米波雷达的静态目标识别与跟踪 [C]. 2021 中国汽车工程学会年会暨展览会, 中国上海, F, 2021.
- [8] SIVARAMAN S, TRIVEDI M M. Looking at Vehicles on the Road: A Survey of Vision-Based Vehicle Detection, Tracking, and Behavior Analysis [J]. Ieee Transactions on Intelligent Transportation Systems, 2013, 14(4): 1773-1795.
- [9] 谭舜泉, 黎思力, 陈保营. 面向图像视频取证的机器学习综述 [J]. 信号处理, 2021, 37(12): 2235-2250.
- [10] O'ROURKE S M, HERSKOWITZ I, O'SHEA E K. Yeast go the whole HOG for the hyperosmotic response [J]. Trends in Genetics, 2002, 18(8): 405-412.
- [11] LOWE D G. Distinctive image features from scale-invariant keypoints [J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [12] NIKNEJAD H T, TAKEUCHI A, MITA S, et al. On-Road Multivehicle Tracking Using Deformable Object Model and Particle Filter With Improved Likelihood Estimation [J]. Ieee Transactions on Intelligent Transportation Systems, 2012, 13(2): 748-758.
- [13] 文学志, 方巍, 郑钰辉. 一种基于类 Haar 特征和改进 AdaBoost 分类器的车辆识别算法 [J]. 电子学报, 2011, 39(05): 1121-1126.
- [14] HINTON G E, OSINDERO S, TEH Y W. A fast learning algorithm for deep belief nets [J]. Neural Computation, 2006, 18(7): 1527-1554.
- [15] ZHU J, ZOU H, ROSSET S, et al. Multi-class AdaBoost [J]. Statistics and Its Interface, 2009, 2(3): 349-360.
- [16] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks [J]. Science, 2006, 313(5786): 504-507.
- [17] GIRSHICK R, DONAHUE J, DARRELL T, et al. Region-Based Convolutional Networks for Accurate Object Detection and Segmentation [J]. Ieee Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(1): 142-158.

- [18] BASBUG A M, SERT M, IEEE. Acoustic Scene Classification Using Spatial Pyramid Pooling With Convolutional Neural Networks; proceedings of the 13th IEEE International Conference on Semantic Computing (ICSC), Newport Beach, CA, F Jan 30-Feb 01, 2019 [C]. 2019.
- [19] 曹诗雨, 刘跃虎, 李辛昭. 基于 Fast R-CNN 的车辆目标检测 [J]. 中国图象图形学报, 2017, 22(05): 671-677.
- [20] 王林, 张鹤鹤. Faster R-CNN 模型在车辆检测中的应用 [J]. 计算机应用, 2018, 38(03): 666-670.
- [21] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection; proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, WA, F Jun 27-30, 2016 [C]. 2016.
- [22] REDMON J, FARHADI A, IEEE. YOLO9000: Better, Faster, Stronger; proceedings of the 30th IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, F Jul 21-26, 2017 [C]. 2017.
- [23] 孔栋, 王晓原, 刘亚奇. 基于车载 32 线激光雷达点云的车辆目标识别算法 [J]. 科学技术与工程, 2018, 18(05): 81-85.
- [24] AZIM A, AYCARD O, IEEE. Detection, Classification and Tracking of Moving Objects in a 3D Environment; proceedings of the IEEE Intelligent Vehicles Symposium (IV), Alcalá de Henares, SPAIN, F Jun 03-07, 2012 [C]. 2012.
- [25] ZHOU Y, TUZEL O, IEEE. VoxelNet: End-to-End Learning for Point Cloud Based 3D Object Detection; proceedings of the 31st IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, F Jun 18-23, 2018 [C]. 2018.
- [26] QI C R, SU H, MO K C, et al. PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation; proceedings of the 30th IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, F Jul 21-26, 2017 [C]. 2017.
- [27] QI C R, YI L, SU H, et al. PointNet plus plus : Deep Hierarchical Feature Learning on Point Sets in a Metric Space; proceedings of the 31st Annual Conference on Neural Information Processing Systems (NIPS), Long Beach, CA, F Dec 04-09, 2017 [C]. 2017.
- [28] 贾子永, 任国全, 李冬伟. 视觉与激光雷达信息融合的目标领航车识别方法 [J]. 火力与指挥控制, 2018, 43(06): 57-61+65.
- [29] 杨晓康. 基于毫米波雷达和视觉的车辆检测识别方法研究 [D]. 郑州:解放军信息工程大学, 2017.
- [30] SUGIMOTO S, TATEDA H, TAKAHASHI H, et al. Obstacle detection using millimeter-wave radar and its visualization on image sequence; proceedings of the 17th International Conference on Pattern Recognition (ICPR), British Machine Vis Assoc, Cambridge, ENGLAND, F Aug 23-26, 2004 [C]. 2004.
- [31] HASELHOFF A, KUMMERT A, SCHNEIDER G, et al. Radar-vision fusion with an application to car-following using an improved AdaBoost detection algorithm; proceedings of the 10th International IEEE Conference on Intelligent Transportation Systems, Bellevue, WA, F Sep 30-Oct 03, 2007 [C]. 2007.
- [32] 谭力凡. 机器视觉与毫米波雷达融合的前方车辆检测方法研究 [D]. 长沙:湖南大学, 2018.
- [33] 那田. 基于雷达和机器视觉融合的前方车辆障碍物检测 [D]. 合肥:合肥工业大学, 2016.

- [34] 陆怡悦, 蔡云飞, 石庭敏. 基于多线激光雷达与视觉信息的实时行人检测 [J]. 计算机与数字工程, 2017, 45(11): 2256-2262.
- [35] 麦新晨. 基于多传感器融合的车辆检测与跟踪 [D]. 上海:上海交通大学, 2011.
- [36] SIDIYA A C, RUBAIYAT A H M, FALLAH Y, et al. Robust Vehicle Environment Reconstruction from Point Clouds For Irregularity Detection; proceedings of the 28th IEEE Intelligent Vehicles Symposium (IV), Redondo Beach, CA, F Jun 11-14, 2017 [C]. 2017.
- [37] 邢皎玉. 基于智能纯电动汽车的前方车辆检测与识别技术研究 [D]. 合肥:合肥工业大学, 2017.
- [38] BRADSKI G, KAEHLER A. Robot-vision signal processing primitives [J]. Ieee Signal Processing Magazine, 2008, 25(1): 130-133.
- [39] ZHANG Z Y. A flexible new technique for camera calibration [J]. Ieee Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(11): 1330-1334.
- [40] 王德志. 激光雷达原理 [J]. 科协论坛(下半月), 2008, (05): 40.
- [41] 安峰. 基于开源操作系统 ROS 的机器人软件开发 [J]. 单片机与嵌入式系统应用, 2017, 17(05): 27-29+33.
- [42] 项志宇, 郑路. 摄像机与 3D 激光雷达联合标定的新方法 [J]. 浙江大学学报(工学版), 2009, 43(08): 1401-1405.
- [43] 蒋进军, 茅时群, 谭兴福. 一种激光雷达和红外摄像头联合标定方法 [J]. 港口装卸, 2021, (05): 5-9.
- [44] 刘钊, 戴斌, 刘大学. 多传感器信息融合中时间同步方法的研究 [J]. 计算机仿真, 2009, 26(06): 124-127.
- [45] 庞成. 基于测距雷达和机器视觉数据融合的前方车辆检测系统 [D]. 南京:东南大学, 2015.
- [46] 韩崇昭. 基于多源信息融合的多目标跟踪理论与应用系统研究 [M]. 西安:西安交通大学出版社, 2007.
- [47] RAJU V M, GUPTA V, LOMATE S, et al. Performance of Open Autonomous Vehicle Platforms: Autoware and Apollo; proceedings of the IEEE 5th International Conference for Convergence in Technology (I2CT), Pune, INDIA, F Mar 29-31, 2019 [C]. 2019.
- [48] 王文远. 基于图像信噪比选择优化高斯滤波尺度 [J]. 电子与信息学报, 2009, 31(10): 2483-2487.
- [49] 高浩军, 杜宇人. 中值滤波在图像处理中的应用 [J]. 电子工程师, 2004, (08): 35-36.
- [50] 戴玉艳, 朱灿焰, 季爱明. 一种基于图像处理的双目视觉校准方法 [J]. 电子设计工程, 2015, 23(16): 178-181.
- [51] AGARWAL P K, PROCOPIUC C M. Exact and approximation algorithms for clustering [J]. Algorithmica, 2002, 33(2): 201-226.
- [52] SCHNABEL R, WAHL R, KLEIN R. Efficient RANSAC for point-cloud shape detection [J]. Computer Graphics Forum, 2007, 26(2): 214-226.
- [53] HOCHREITER S, SCHMIDHUBER J. Long short-term memory [J]. Neural Computation, 1997, 9(8): 1735-1780.
- [54] SUNDERMEYER M, NEY H, SCHLUTER R. From Feedforward to Recurrent LSTM Neural Networks for Language Modeling [J]. Ieee-Acm Transactions on Audio Speech and Language Processing, 2015, 23(3): 517-529.

- [55] LEI H J, HAN T, ZHOU F, et al. A deeply supervised residual network for HEp-2 cell classification via cross-modal transfer learning [J]. Pattern Recognition, 2018, 79: 290-302.
- [56] 赵蓬辉, 孟春宁, 常胜江. 基于改进 VGG 网络的单阶段船舶检测算法 [J]. 光电子·激光, 2019, 30(07): 719-730.
- [57] 阮激扬. 基于 YOLO 的目标检测算法设计与实现 [D]. 北京:北京邮电大学, 2019.
- [58] 乔曦, 钱万强, 樊伟. 基于深度学习的野外薇甘菊图像识别[C]. 第五届全国入侵生物学大会——入侵生物与生态安全, 中国新疆乌鲁木齐, F, 2018.
- [59] YANG W, ZHANG J, WANG H Y, et al. A Vehicle Real-time Detection Algorithm Based on YOLOv2 Framework; proceedings of the Conference on Real-Time Image and Video Processing, Orlando, FL, F Apr 16-17, 2018 [C]. 2018.
- [60] MIJIC D, BRISINELLO M, VRANJES M, et al. Traffic Sign Detection Using YOLOv3; proceedings of the 10th IEEE International Conference on Consumer Electronics (ICCE-Berlin), Berlin, GERMANY, F Nov 09-11, 2020 [C]. 2020.
- [61] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: Common Objects in Context; proceedings of the 13th European Conference on Computer Vision (ECCV), Zurich, SWITZERLAND, F Sep 06-12, 2014 [C]. 2014.
- [62] JOHANSEN T A, PEREZ T, CRISTOFARO A. Ship Collision Avoidance and COLREGS Compliance Using Simulation-Based Control Behavior Selection With Predictive Hazard Assessment [J]. Ieee Transactions on Intelligent Transportation Systems, 2016, 17(12): 3407-3422.
- [63] NAEEM W, IRWIN G W, YANG A L. COLREGs-based collision avoidance strategies for unmanned surface vehicles [J]. Mechatronics, 2012, 22(6): 669-678.
- [64] 谢江, 汪同庆. 基于最大类间方差法的快速交通视频运动目标分割方法 [J]. 计算机系统应用, 2010, 19(09): 151-154.

致 谢

转眼之间，我的三年研究生生活即将画上句号，我与大连海事大学和这里的老师同学们朝夕相处、一同工作学习的日子也进入了倒计时。在此，我要向这三年围绕在我身边，给予我鼓励帮助的每一个人表达我最真诚的感激之情。

一、我要感谢我的研究生母校，大连海事大学。在疫情封校期间，学校的各项政策都是以尽量满足每位同学的需求为前提。为了保障同学们身心状态良好，学校专门设立心理咨询室，为学生们提供专业的心理指导；为了满足同学们的饮食健康要求，学校为大家提供免费的鸡蛋、鸡腿，当同学们想吃校外的某些小吃，学校也是尽其所能满足大家的要求，我为我身在“别人家的大学”而感到骄傲！

二、我要感谢我的导师，关巍老师。虽然关老师平时的工作和科研任务极其繁重，但老师总会抽出足够的时间耐心地为我的解答科研上的疑惑、讨论研究的内容方向等。只要是学生提出来的要求，关老师都会尽力满足，且态度一直都是和颜悦色、和蔼可亲的。他是我们的导师，却更像是我们的朋友，他可以设身处地地为我们着想，理解我们、包容我们，始终将我们的利益放在第一位。这三年，关老师对我的帮助和理解，得到了许多小伙伴的羡慕之声，我为拥有这样一位优秀的导师而感到骄傲和自豪！关老师对我的恩情，我也会一直铭记在心里，在此以最真诚的字句表达我对关老师的敬意和感激之情！

三、我要感谢我的师兄师弟师妹：周浩田、张涛、周庆宏、曹伟男、孙静海、王思琪、彭颢文、张成宝、王阔、赵明阳等人在科研和学习上对我的帮助和鼓励。还要感谢我的室友：段雅婷、李新宇、胡蓉等人在学习和生活上对我的各种帮助，还有我最好的研究生小伙伴刘美芳，是她们陪我度过了疫情期间单调但不枯燥乏味的研究生生活，我们的感情我会用一辈子去珍惜！

感谢大家！

作者简介及攻读硕士学位期间的科研成果

作者简介

姓名：倪桦

性别：女

出生年月：1996 年 01 月 30 日

民族：汉

籍贯：辽宁大连

研究方向：交通运输工程

主要教育经历

2014.09-2018.07，鞍山师范学院，数学与信息科学学院，计算机科学与技术，本科

2019.09-2022.07，大连海事大学，航海学院，交通运输工程，硕士

攻读硕士学位期间的科研成果

1. 发表学术论文

EI会议：[1] H. N., W. G, C. W. USV Obstacle Avoidance Based on Improved Watershed and VFH Method; proceedings of the 11th International Conference on Prognostics and System Health Management (PHM-2020), Jinan [C]. 2020.

EI会议：[2] X. Chen, H. Ji, C. Huo, H. Ni and W. Guan. A Unidimension Histogram Grid Algorithm for ISV Real Time Obstacle Avoidance; proceedings of the 2019 International Conference on Intelligent Computing, Automation and Systems (ICICAS), Xian[C]. 2019.

中文核心：[3] 倪桦,关巍,张显库.基于激光雷达与摄像头的无人船目标感知与定位（已录用，待发表）

2.参与科研项目

[1] 国家自然科学基金委，面上项目，多船会遇局面下的 MASS 自主行为决策与控制策略研究（52171342）

[2] 国家市场监督管理总局标准技术管理司，标准制修订项目，《全球海上遇险和安全系统（GMDSS）术语》国家标准制修订项目（TJTNY2020009002）

[3] 中华人民共和国扬州海事局，研究类项目，《微型无人船在海事管理的可行性研究》

3.获得奖励情况

[1] 辽宁省研究生数学建模，三等奖，2019.11，队长。

[2] 2020 届挑战杯辽宁省大学生创业计划竞赛，铜奖，2020.08，队长。

[3] 第七届共享杯大学生科技资源共享服务创新大赛，三等奖及百度奖学金，2020.03 组员。

[4] 学业二等奖学金，2019.11。

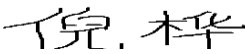
[5] 学业一等奖学金，2020.11。

[6] 学业二等奖学金，2021.11。

7 大连海事大学学位论文授权使用声明

本人完全了解并同意遵守学校有关学位论文知识产权的规定，在校攻读学位期间论文工作的知识产权属于大连海事大学，学校有权保留送交学位论文的副本，向国家有关部门或机构送交论文的复印件和电子版，允许该论文被查阅，可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印、或扫描等复制手段保存和汇编本学位论文。

涉密的学位论文在解密后使用本声明。

作者签名：_____  _____ 日期：_____ 2022 年 6 月 7 日

导师签名：_____  _____ 日期：_____ 2022 年 6 月 7 日

备注：提交时须有作者和导师亲笔签名！